Batch Normalization ve Dropout ile İlişkisi

Atıl Samancıoğlu

1 Giriş: Neden Batch Normalization'a İhtiyacımız Var?

Derin öğrenmede şimdiye kadar şunları gördük:

- Aktivasyon fonksiyonları
- Loss fonksiyonları
- Optimizer'lar
- Weight initialization
- Dropout ile overfitting kontrolü

Peki şu soruyu soralım:

Model doğru öğreniyor ama neden yavaş öğreniyor?

Ya da:

Aynı model, küçük bir learning rate değişiminde neden tamamen bozuluyor?

Bu problemlerin merkezinde şu kavram vardır:

Dağılım (Distribution) Problemi

Batch Normalization tam olarak bu problemi çözmek için ortaya çıkmıştır.

2 Hidden Layer'larda Gizli Problem

Bir neural network'te her katman:

- Önce lineer işlem yapar ($z = Wx + b$)
- Sonra aktivasyon uygular

Ancak önemli bir gerçek var:

Bir katmanın çıktısı, bir sonraki katmanın girdisidir.

Şimdi düşün:

- İlk epoch'ta z değerleri küçük
- Sonraki epoch'ta weight'ler değişti
- z dağılımı tamamen kaydı

Bu duruma:

Internal Covariate Shift

denir.

Anlamı şudur:
Her katman, sürekli değişen bir dağılıma uyum sağlamaya çalışır.
Sonuç:

- Eğitim yavaşlar
- Gradient'ler kararsızlaşır
- Learning rate seçimi zorlaşır

3 Batch Normalization'ın Temel Fikri

Batch Normalization şunu söyler:

> *Her katmanın çıktısını kontrollü bir dağılıma sokalım.*

Yani:

- Ortalama (mean) $= 0$
- Varyans (variance) $= 1$

Bu sayede:

- Katmanlar daha stabil öğrenir
- Gradient'ler patlamaz / sönmez

4 Batch Normalization Nasıl Çalışır?

Bir batch düşünelim:

$$\{z_1, z_2, \ldots, z_m\}$$

4.1 Adım 1: Ortalama

$$\mu = \frac{1}{m} \sum_{i=1}^{m} z_i$$

4.2 Adım 2: Varyans

$$\sigma^2 = \frac{1}{m} \sum_{i=1}^{m} (z_i - \mu)^2$$

4.3 Adım 3: Normalize Et

$$\hat{z}_i = \frac{z_i - \mu}{\sqrt{\sigma^2 + \epsilon}}$$

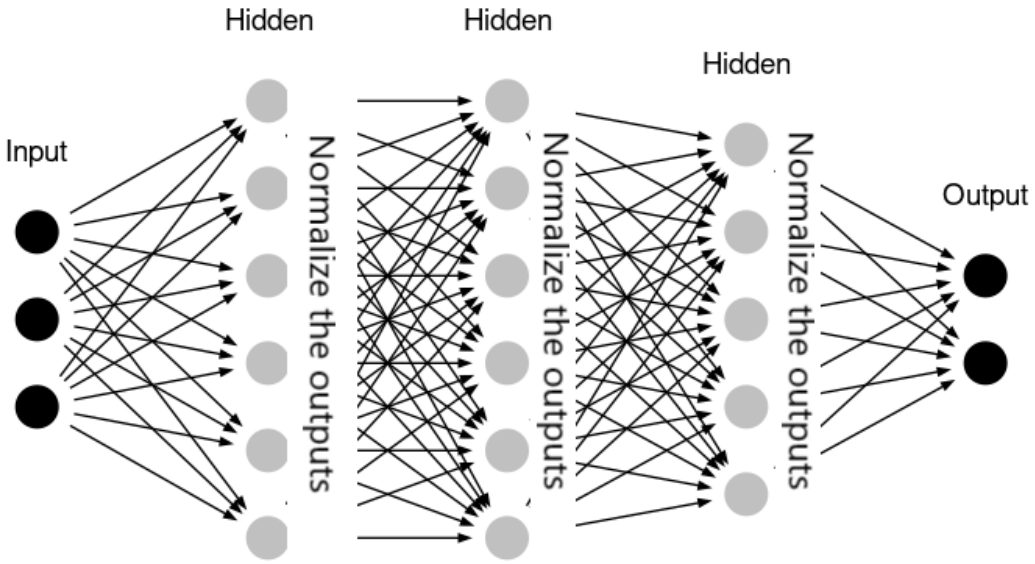

Figure 1: Batch Normalization

4.4 Adım 4: Ölçekle ve Kaydır

$$y_i = \gamma \hat{z}_i + \beta$$

Burada:

- γ : ölçek (learnable)
- β : kaydırma (learnable)

Model isterse normalizasyonu geri alabilir.

5 Batch Normalization Ne Kazandırır?

BatchNorm sayesinde:

- Daha yüksek learning rate kullanılabilir
- Eğitim daha hızlı yakınsar
- Weight initialization daha az kritik olur

Ve çok önemli bir yan etki:

BatchNorm doğal bir regularization etkisi yaratır.

Neden?
Çünkü:

- Batch istatistikleri her adımda biraz farklıdır
- Bu da modele hafif bir gürültü ekler

6 Batch Normalization ve Dropout İlişkisi

Buraya kadar Dropout ve BatchNorm'u ayrı ayrı öğrendik.
Şimdi kritik soru:

İkisini birlikte kullanmalı mıyız?

6.1 Dropout Ne Yapıyordu?

- Rastgele nöronları kapatıyordu
- Feature co-adaptation'ı engelliyordu

6.2 BatchNorm Ne Yapıyor?

- Aktivasyonları stabilize ediyor
- Gürültü ekleyerek regularization sağlıyor

Problem şurada:
Dropout:

- Aktivasyonları rastgele sıfırlıyor

BatchNorm:

- Aktivasyon dağılımını ölçmeye çalışıyor

Dropout, BatchNorm'un ölçmeye çalıştığı dağılımı sürekli bozuyor.

7 Pratikte Ne Yapıyoruz?

Modern derin öğrenmede genel yaklaşım:

- BatchNorm varsa:
  - Dropout ya hiç kullanılmaz
  - Ya da çok düşük oranla kullanılır
- CNN ve Transformer modellerinde:
  - BatchNorm / LayerNorm tercih edilir
  - Dropout sınırlı kullanılır

BatchNorm çoğu zaman Dropout'un yerini alır.

8 Özet

- BatchNorm, katman içi dağılım problemini çözer
- Eğitimi hızlandırır ve stabilize eder
- Doğal bir regularization etkisi vardır
- Dropout ile aynı anda dikkatli kullanılmalıdır

Dropout modeli zorlar, BatchNorm modeli dengeler.